Nhận Dạng Động Tác Thể Dục Dụng Cụ Với Mạng Tích Chập Đồ Thị Không-Thời Gian Bằng Khung Xương

Đỗ Nhật Minh – 21127355
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Lê Anh Duy – 23127011
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

***Tóm tắt nội dung*—Bài báo này trình bày ứng dụng Mạng Tích Chập Đồ Thị Không-Thời Gian (ST-GCN) cho bài toán nhận dạng hành động thể dục tự do chi tiết trên tập con FX của Gym99 – 35 lớp hành động, 8.235 chuỗi khung xương trích xuất từ bộ dữ liệu FineGym. Chúng tôi xây dựng đồ thị khung xương 18 khớp (COCO-17 cộng một khớp trung tâm ảo) với chiến lược phân vùng cấu hình không gian và tiến hành ba chuỗi thực nghiệm có hệ thống. Mô hình cơ sở đơn luồng đạt Best Val Acc = 88,95%, Macro F1 = 87,41%. Thử nghiệm kết hợp đồng thời nhiều kỹ thuật (hai luồng, chuẩn hóa bounding-box, Focal Loss, oversample $3\times$) cho kết quả thấp hơn (Best Val Acc = 78,82%) do quá khớp nghiêm trọng, chỉ ra rằng chuẩn hóa bounding-box loại bỏ thông tin tỉ lệ cơ thể quan trọng cho nhận dạng chi tiết. Thử nghiệm với nhiều độ sâu trên kiến trúc hai luồng với chuẩn hóa trung tâm, Focal Loss đạt kết quả tốt nhất ở kiến trúc gồm 6 khối ST-Conv (Best Val Acc = 89,68%, Macro F1 = 87,19%), tương đương mô hình cơ sở và vượt đáng kể so với cấu hình kết hợp đầy đủ.**

***Index Terms*—nhận dạng hành động chi tiết, khung xương, ST-GCN, FineGym, Gym99, tích chập đồ thị, hai luồng**

I. Giới Thiệu

Nhận dạng hành động người (Human Action Recognition – HAR) là một trong những bài toán quan trọng của thị giác máy tính, với ứng dụng trong phân tích thể thao, giám sát an ninh và hỗ trợ y tế phục hồi chức năng [1]. Trong khi các hệ thống trước đó chủ yếu giải quyết nhận dạng ở cấp độ *thô* (coarse-grained) – phân biệt "chạy" với "nhảy" – thách thức ngày càng được chú ý là nhận dạng *chi tiết* (fine-grained): phân biệt các biến thể tinh tế trong cùng một nhóm hành động. Thể dục dụng cụ là lĩnh vực ứng dụng tiêu biểu: các động tác như "lăn ra trước" và "lăn ra sau" có cấu trúc khung xương gần như đối xứng, sự khác biệt nằm chủ yếu ở thứ tự và pha thời gian của các khớp chứ không phải tư thế tức thời.

Các phương pháp dựa trên đặc trưng RGB thô thường nhạy cảm với ánh sáng, trang phục và góc máy quay. Biểu diễn đối tượng dưới dạng khung xương khắc phục hạn chế này: cơ thể người được mô hình hóa như một đồ thị cấu trúc bất biến với nhiều nhiễu quang học. ST-GCN (Spatial Temporal Graph Convolutional Networks) của Yan *và cộng sự* [1] là mô hình đầu tiên áp dụng tích chập đồ thị lên chuỗi khung xương động, học đồng thời cấu trúc không gian và sự thay đổi theo thời gian của chuyển động, trong một khoảng thời gian thống nhất.

Tập dữ liệu FineGym [14] cung cấp benchmark cho nhận dạng hành động chi tiết trong thể dục nghệ thuật. Gym99 là tập con gồm 99 lớp hành động cụ thể (36.665 chuỗi khung xương) phân bố trên bốn dụng cụ. Vì để có thể nghiên cứu tập trung vào kiến trúc mô hình nên các thực nghiệm trong bài báo cáo này tập trung vào **tập con FX** (Floor Exercise – thể dục tự do): 35 lớp, 8.235 chuỗi, với mức độ mất cân bằng lớp $8\times$ và Gini = 0,306 – một benchmark chi tiết đòi hỏi cao nhưng có kích thước vừa đủ để nghiên cứu kỹ lưỡng.

Bài báo này có các đóng góp sau:

- Xây dựng và phân tích dữ liệu khám phá (EDA) toàn diện cho tập con FX của Gym99, bao gồm phân phối lớp, độ dài chuỗi, vận tốc khớp, và khả năng phân tách lớp trong không gian đặc trưng.
- Thiết kế biểu diễn khung xương 18 node thống nhất (COCO-17 + node trung tâm ảo) tương thích với cả hai luồng joint và bone, cho phép tái sử dụng pipeline trên nhiều tập dữ liệu.
- Triển khai và so sánh hai cấu hình ST-GCN trên tập FX: mô hình cơ sở đơn luồng và mô hình hai luồng kết hợp Focal Loss, chuẩn hóa bounding-box và các kỹ thuật chống overfitting.
- Áp dụng Focal Loss với hệ số $\alpha_t = 1/\sqrt{f_t}$ (nghịch đảo căn bậc hai tần suất lớp) để giảm thiểu độ lệch học do mất cân bằng lớp trong tập FX.

Phần còn lại của bài báo được tổ chức như sau: Phần II tổng quan các nghiên cứu liên quan; Phần III mô tả Gym99 và phân tích tập con FX; Phần IV trình bày kiến trúc ST-GCN và các lựa chọn thiết kế; Phần V báo cáo kết quả thực nghiệm; Phần VI kết luận.

II. Các Nghiên Cứu Liên Quan

A. Nhận Dạng Hành Động Dựa Trên Khung Xương

Hướng nghiên cứu dựa trên khung xương khai thác tọa độ 2D/3D của các khớp cơ thể người như một biểu diễn gọn nhẹ, bất biến với nhiều biến đổi ngoại cảnh. Các phương pháp sớm sử dụng các đặc trưng thủ công như hiệp phương sai quỹ đạo khớp [11], vị trí tương đối giữa các khớp [12], hay góc xoay và tịnh tiến giữa các phần cơ thể [13]. Sự ra đời của học sâu đã thúc đẩy việc sử dụng mạng hồi quy (RNN/LSTM) để mô

hình hóa chuỗi thời gian khớp [8], [9], và sau đó là mạng tích chập thời gian (TCN) [10].

Bước đột phá quan trọng đến từ ST-GCN [1]: thay vì làm phẳng khung xương thành vector một chiều, mô hình xây dựng đồ thị không-thời gian và áp dụng tích chập đồ thị để học không gian cùng tích chập thời gian để học các thay đổi chuyển động theo thời gian. Tiếp theo, AGCN [2] đề xuất ma trận kề có thể học được để nắm bắt những đóng góp của từng cạnh theo cấu hình của đồ thị; MS-G3D [3] thống nhất tích chập đa tỉ lệ không gian và thời gian vào một toán tử duy nhất; CTR-GCN [4] tập trung học biến đổi kênh theo ngữ cảnh cho từng mẫu đầu vào.

B. Mạng Tích Chập Đồ Thị

Nền tảng lý thuyết của ST-GCN là mạng tích chập đồ thị (GCN). Hai hướng chính hình thành GCN là hướng *phổ* (spectral), xử lý tín hiệu trên đồ thị qua biến đổi Fourier đồ thị [5], [6], và hướng *không gian* (spatial), định nghĩa tích chập trực tiếp trên các hàng xóm trong trên đồ thị [7]. ST-GCN theo hướng không gian và phân vùng tập hàng xóm của mỗi node thành K tập con ứng với K ma trận kề – mỗi ma trận học một bộ trọng số tích chập riêng. Chiến lược phân vùng cấu hình không gian (Spatial Configuration Partitioning) phân chia hàng xóm theo khoảng cách đến trọng tâm của khung xương, phản ánh tính chất hướng tâm-ngoại tâm của các khớp khi cơ thể chuyển động.

C. Mô Hình Hai Luồng Cho Khung Xương

Shi *và cộng sự* [2] chỉ ra rằng kết hợp thông tin khớp (joint) và thông tin xương (bone – véc-tơ sai phân giữa hai đầu mỗi cạnh) trong hai luồng song song cải thiện đáng kể hiệu năng phân loại. Luồng joint mã hóa vị trí tuyệt đối của các khớp; luồng bone mã hóa độ dài và hướng của từng đoạn xương, bất biến hơn với dịch chuyển toàn cục. Tại thời điểm suy luận, điểm số phân loại từ hai luồng được cộng trực tiếp (score fusion). Kiến trúc này trở thành cơ sở thực nghiệm trong nhiều công trình kế tiếp.

D. Nhận Dạng Hành Động chi tiết Trong Thể Thao

FineGym [14] là tập dữ liệu hành động chi tiết đầu tiên tập trung vào thể dục nghệ thuật, với ba cấp độ phân loại phân cấp: sự kiện (event), tập hợp các hành động lớn (set), và hành động chi tiết (element). Gym288 và Gym99 là hai tập con phổ biến được dùng làm benchmark. Điểm đặc trưng của dữ liệu này là: (1) sự tương đồng trực quan rất cao giữa nhiều lớp; (2) mất cân bằng lớp nghiêm trọng; (3) biến đổi lớn trong độ dài clip; (4) video từ camera cố định trong thi đấu thực tế, tạo ra phân phối rất khác so với dataset dân dụng thông thường. Một số nghiên cứu gần đây sử dụng đặc trưng RGB kết hợp [14] hoặc attention cấu trúc đồ thị [15] để giải quyết bài toán này; tuy nhiên, hướng tiếp cận chỉ dùng khung xương trên Gym99 vẫn còn ít được khám phá.

III. Tập Dữ Liệu Gym99

A. Tổng Quan Gym99

Gym99 là tập con của FineGym288 [14] gồm 99 lớp hành động, phân bố trên bốn dụng cụ: Vault (VT, 6 lớp), Floor Exercise (FX, 35 lớp), Balance Beam (BB, 33 lớp), và Uneven Bars (UB, 25 lớp). Chú thích khung xương được lấy trực tiếp từ bộ dữ liệu FineGym288 theo ánh xạ nhãn chính thức (*clabel* $\rightarrow$ *glabel*) công bố tại trang chủ FineGym. Bảng 1 tóm tắt thống kê của toàn bộ Gym99; các thực nghiệm trong bài báo này tập trung hoàn toàn vào dữ liệu ở mức hành động chi tiết từ tập con **FX**. FX được chọn vì có số mẫu đủ lớn và độ khó phù hợp với hướng tiếp cận chỉ dùng khung xương. Phân tích tập FX được trình bày ở Mục III-C.

Bảng 1
Thống Kê Tập Dữ Liệu Gym99

Thuộc tính	Giá trị
Tổng số mẫu	36.665
Tập huấn luyện	27.624
Tập kiểm tra	9.041
Số lớp hành động	99
Số khớp mỗi frame	17 (COCO) + 1 (trung tâm) = 18
Độ dài chuỗi (sau lấy mẫu lại)	48 frame
Số mẫu lớp nhỏ nhất	79
Số mẫu lớp lớn nhất	2.060
Tỉ lệ mất cân bằng max/min	$\approx 26\times$
Gini coefficient	0,438

B. Biểu Diễn Khung Xương

Bộ chú thích FineGym288 lưu trữ keypoint theo định dạng COCO-17: tensor $(1, T, 17, 2)$ với tọa độ pixel trong không gian ảnh gốc (1920×1080). Chúng tôi giữ nguyên tất cả 17 khớp bao gồm cả các điểm mặt (mắt, tai) vì chúng đóng góp vào phân vùng hướng tâm/ly tâm của đồ thị. Một **node trung tâm ảo** (chỉ số 17) được thêm vào như trung bình của bốn khớp gốc:

$$\mathbf{p}_{17} = \frac{1}{4}\big(\mathbf{p}_{\text{l_sho}} + \mathbf{p}_{\text{r_sho}} + \mathbf{p}_{\text{l_hip}} + \mathbf{p}_{\text{r_hip}}\big).$$

Tensor đầu vào cho ST-GCN có dạng $(N, C{=}2, T{=}48, V{=}18, M{=}1)$ trong đó C là số kênh tọa độ (x, y), T là số frame (lấy mẫu lại đều về 48), V là số node, và M là số người.

Biểu diễn này được sử dụng trực tiếp làm đầu vào cho luồng joint của ST-GCN. Luồng bone – được trình bày chi tiết trong Mục IV-G – tính sai phân véc-tơ theo từng cạnh đồ thị: với mỗi cạnh (u, v), đặc trưng bone là $\mathbf{p}_v - \mathbf{p}_u$, tạo ra tensor cùng kích thước mã hóa độ dài và hướng của từng đoạn xương.

C. Phân Tích Tập Con FX

Phân phối lớp và mức độ mất cân bằng. Tập FX gồm 35 lớp hành động (nhãn toàn cục $[6, 40]$), với 5.824 mẫu huấn luyện và 2.411 mẫu kiểm tra (tổng 8.235). So với toàn bộ Gym99, mức độ mất cân bằng lớp nhẹ hơn đáng kể: tỉ lệ max/min là $8\times$ (thay vì $26\times$) và Gini = 0,306 (thay vì 0,438). Số lớp hiệu dụng (effective number of classes) đạt 30,1 trên 35, cho thấy phân phối tương đối đồng đều dù vẫn cần chiến lược xử lý mất cân bằng. Hình 1 minh họa phân phối kích thước lớp và đường cong Lorenz tương ứng.

Phân phối độ dài video. Hình 2 cho thấy phân phối số frame thô của các video FX trước khi lấy mẫu lại. Phần lớn

Bảng 2
THỐNG KÊ TẬP CON FX (FLOOR EXERCISE)

Thuộc tính	Giá trị
Tổng số mẫu	8.235
Tập huấn luyện	5.824
Tập kiểm tra	2.411
Số lớp hành động	35
Nhãn toàn cục	[6, 40]
Số khớp mỗi frame	17 (COCO) + 1 (trung tâm) = 18
Độ dài chuỗi (sau lấy mẫu lại)	48 frame
Số mẫu lớp nhỏ nhất	80
Số mẫu lớp trung vị	193
Số mẫu lớp lớn nhất	633
Tỉ lệ mất cân bằng max/min	$\approx 8\times$
Gini coefficient	0,306
Số lớp hiệu dụng	30,1 / 35

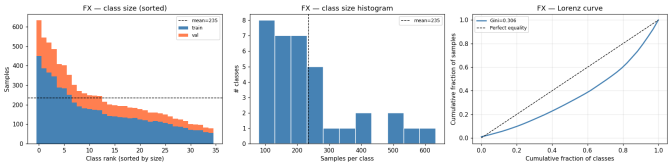

Hình 1. Phân phối lớp tập con FX (35 lớp, train=5.824 / val=2.411). *Trái*: kích thước mỗi lớp sắp xếp giảm dần (xanh = train, cam = val), đường ngang = trung bình 235 mẫu. *Giữa*: histogram số mẫu/lớp, phản ánh phân phối lệch phải nhẹ. *Phải*: đường cong Lorenz (Gini = 0,306) – gần đường lý tưởng hơn toàn bộ Gym99 (Gini = 0,438), nhưng 5 lớp nhỏ nhất vẫn chỉ chiếm $\sim$8% tổng mẫu.

clip có độ dài dưới 64 frame (đường đỏ – ngưỡng lấy mẫu mục tiêu), đặt ra vấn đề padding cho các video ngắn và cần chú ý khi thiết kế chiến lược lấy mẫu theo thời gian.

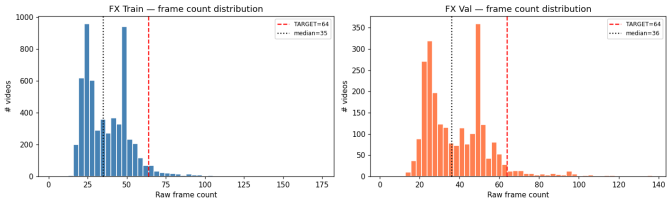

Hình 2. Phân phối số frame thô của tập train FX (trái) và val (phải). Đường đỏ nét đứt = ngưỡng lấy mẫu mục tiêu 64 frame; đường đen chấm = trung vị. Phần lớn clip ngắn hơn ngưỡng – các chuỗi frame này sẽ được padding khi lấy mẫu lại về 64 frame.

Phân tích vận tốc khớp. Hình 3 so sánh vận tốc tuyệt đối trung bình (pixel/frame) của 18 khớp COCO trên toàn bộ tập train FX. Các khớp chi trên (cổ tay, khuỷu tay) và chi dưới (mắt cá chân, đầu gối) có vận tốc cao hơn đáng kể so với các khớp trục thân (hông, vai), phản ánh đặc trưng động học của bài thể dục tự do: tay chân vận động mạnh trong khi thân người duy trì ổn định tương đối. Quan sát này gợi ý rằng các khớp chi ngoại biên mang nhiều thông tin phân biệt lớp hơn.

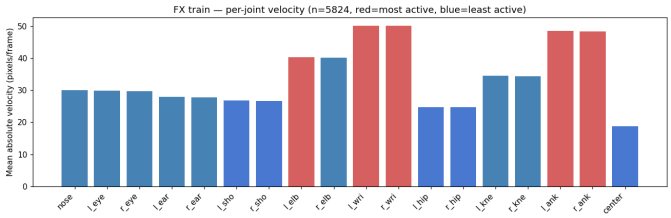

Hình 3. Vận tốc tuyệt đối trung bình (pixel/frame) của 18 khớp COCO trên tập train FX. Màu đỏ: khớp thuộc Q3 trở lên (hoạt động nhất); màu xanh dương: khớp thuộc Q1 trở xuống (ít hoạt động nhất). Các khớp chi ngoại biên (cổ tay, mắt cá chân) di chuyển nhanh hơn $2\times$ so với các khớp trục thân.

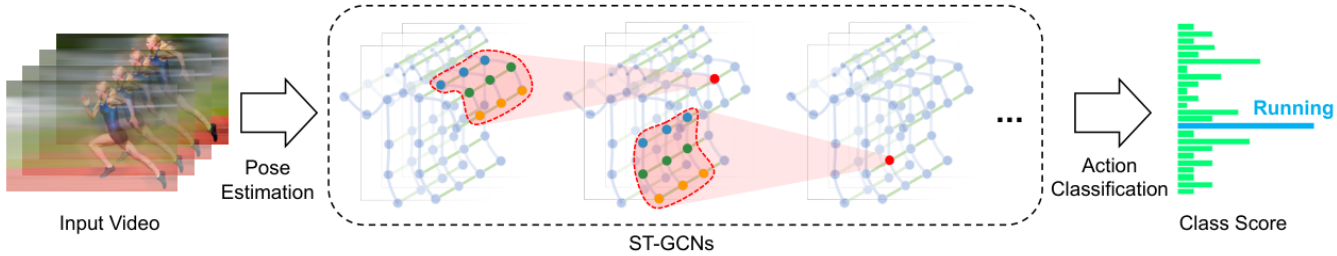

Hình 4. Pipeline tổng quát của ST-GCN (hình từ bài báo gốc [1]): ước lượng tư thế từ video đầu vào tạo ra chuỗi tọa độ khớp; các tọa độ này được tổ chức thành đồ thị không-thời gian; nhiều lớp ST-GCN áp dụng tích chập đồ thị không gian và tích chập thời gian xen kẽ nhau để trích xuất đặc trưng cấp cao; cuối cùng một bộ phân loại Softmax đưa ra nhãn hành động.

IV. Kiến Trúc ST-GCN

A. Đồ Thị Không-Thời Gian

ST-GCN [1] biểu diễn một chuỗi khung xương N khớp trong T frame dưới dạng đồ thị vô hướng $\mathcal{G} = (\mathcal{V}, \mathcal{E})$. Tập node $\mathcal{V} = \{v_{ti} \mid t = 1, \ldots, T;\ i = 1, \ldots, N\}$ gồm $T \times N$ node, mỗi node v_{ti} ứng với khớp i tại frame t. Tập cạnh $\mathcal{E}$ gồm hai loại như minh họa trong Hình 5:

- **Cạnh không gian** $\mathcal{E}_S = \{v_{ti}v_{tj} \mid (i,j) \in H,\ \forall t\}$: nối các khớp có kết nối giải phẫu trong cùng một frame, trong đó H là tập liên kết xương của cơ thể người.
- **Cạnh thời gian** $\mathcal{E}_F = \{v_{ti}v_{(t+1)i} \mid \forall t, i\}$: nối cùng một khớp giữa hai frame liên tiếp, mã hóa quỹ đạo chuyển động theo thời gian.

Trong triển khai của chúng tôi, đồ thị 18 node gồm 19 cạnh không gian giải phẫu (theo cấu trúc COCO-17) và 4 cạnh bổ sung nối node trung tâm ảo (chỉ số 17) với hai khớp vai và hai khớp hông, tổng cộng 23 cạnh không gian. Mỗi khớp trong T frame tạo ra $(T-1)$ cạnh thời gian.

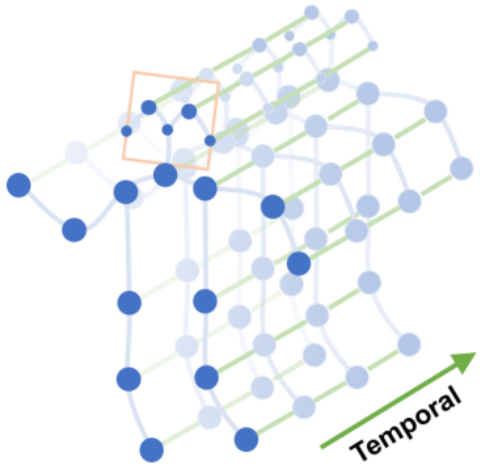

Hình 5. Đồ thị không-thời gian của chuỗi khung xương trong ST-GCN (hình từ bài báo gốc [1]). **Chấm xanh đậm**: node khớp; **cạnh xanh dương**: kết nối giải phẫu trong cùng frame ($\mathcal{E}_S$); **cạnh xanh lá**: liên kết thời gian giữa các frame liên tiếp ($\mathcal{E}_F$).

B. Tích Chập Đồ Thị Không Gian

Tích chập 2D chuẩn được định nghĩa qua hàm lấy mẫu $\mathbf{p}$ và hàm trọng số $\mathbf{w}$:

$$f_{\text{out}}(\mathbf{x}) = \sum_{h=1}^{K} \sum_{w=1}^{K} f_{\text{in}}\big(\mathbf{p}(\mathbf{x}, h, w)\big) \cdot \mathbf{w}(h, w), \tag{1}$$

trong đó lưới không gian $K \times K$ cung cấp cấu trúc lân cận có thứ tự cố định. Trên đồ thị không có lưới nội tại như vậy; ST-GCN giải quyết bằng cách thay hàm lấy mẫu bằng tập lân cận $B(v_{ti})$ của node v_{ti} và thay thứ tự vị trí bằng ánh xạ nhãn phân vùng l_{ti}:

$$f_{\text{out}}(v_{ti}) = \sum_{v_{tj} \in B(v_{ti})} \frac{1}{Z_{ti}(v_{tj})} f_{\text{in}}(v_{tj}) \cdot \mathbf{w}\big(l_{ti}(v_{tj})\big), \tag{2}$$

trong đó $Z_{ti}(v_{tj}) = |\{v_{tk} \mid l_{ti}(v_{tk}) = l_{ti}(v_{tj})\}|$ chuẩn hóa theo kích thước tập phân vùng, và $l_{ti} : B(v_{ti}) \to \{0, \ldots, K-1\}$ là ánh xạ nhãn phân vùng xác định cách chia tập hàng xóm thành K nhóm – mỗi nhóm dùng chung một bộ trọng số tích chập. Thiết kế của l_{ti} quyết định năng lực biểu diễn của mô hình và được trình bày trong Mục IV-C.

C. Chiến Lược Phân Vùng

Ánh xạ nhãn l_{ti} quyết định cách chia tập hàng xóm thành K tập con (Hình 6). ST-GCN đề xuất ba chiến lược:

1) Uni-labeling ($K = 1$): Toàn bộ tập hàng xóm được gán cùng nhãn: $l_{ti}(v_{tj}) = 0,\ \forall i, j$. Đây là chiến lược đơn giản nhất, tương đương với lan truyền đồng nhất của GCN chuẩn [5], nhưng làm mất thông tin về cấu trúc cục bộ.

2) Distance Partitioning ($K = 2$): Phân vùng theo khoảng cách đến node gốc: node gốc ở tập $d = 0$, hàng xóm ở tập $d = 1$: $l_{ti}(v_{tj}) = d(v_{tj}, v_{ti})$. Chiến lược này cho phép mô hình học khác biệt giữa node trung tâm và các khớp lân cận.

3) Spatial Configuration Partitioning ($K = 3$): Với mỗi cạnh (i, j) trong đồ thị, nhãn phân vùng được xác định bằng cách so sánh *khoảng cách hop* (graph distance) từ mỗi đầu cạnh đến **node trung tâm ảo** c – một node cố định được

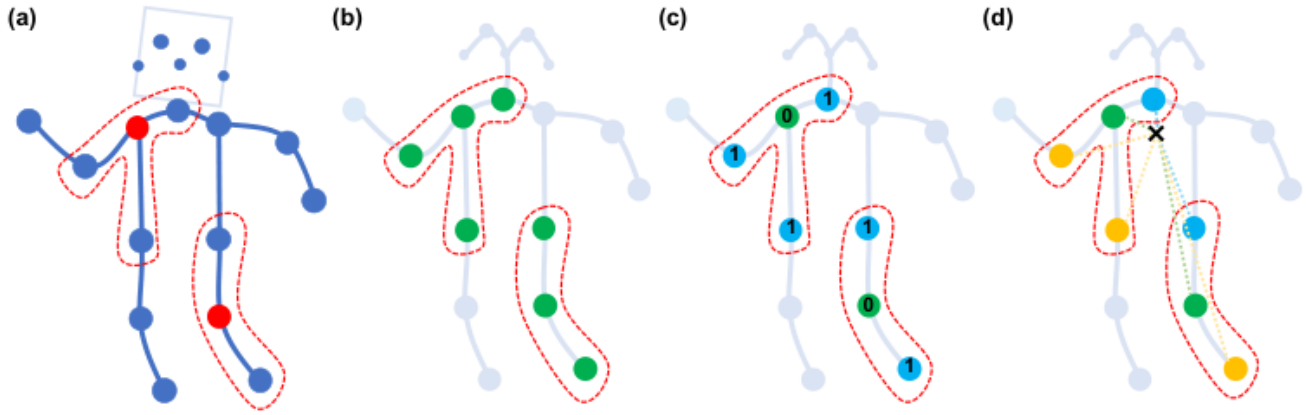

Hình 6. Ba chiến lược phân vùng được đề xuất trong ST-GCN (Yan *et al.* [1], hình từ bài báo gốc): (a) frame khung xương mẫu; (b) Uni-labeling (K=1): toàn bộ hàng xóm cùng nhãn (xanh lá); (c) Distance partitioning (K=2): node gốc nhãn 0 (xanh lá), hàng xóm nhãn 1 (xanh lam); (d) Spatial configuration (K=3): self-loop và đồng hop (xanh lá), hướng tâm – ít hop đến center hơn node gốc (xanh lam), ly tâm – nhiều hop hơn (vàng cam). Chúng tôi sử dụng chiến lược (d).

chèn vào đồ thị khung xương (khớp trung tâm, chỉ số 17 trong COCO-18):

$$l(i \to j) = \begin{cases} 0 & \text{nếu } r_j = r_i \quad \text{(self-loop hoặc đồng hop)} \\ 1 & \text{nếu } r_j < r_i \quad \text{(hướng tâm – về phía center)} \\ 2 & \text{nếu } r_j > r_i \quad \text{(ly tâm – ra xa center)} \end{cases} \tag{3}$$

trong đó $r_i = \text{hop}(c, i)$ là số cạnh trên đường đi ngắn nhất từ node trung tâm c đến khớp i trong đồ thị xương. Nói cách khác, khớp nào gần trung tâm hơn theo cấu trúc đồ thị (ít hop hơn) thì thuộc nhóm hướng tâm; khớp xa hơn thuộc nhóm ly tâm; hai khớp cùng số hop đến trung tâm thì cùng tập phân vùng 0.

Ba ma trận kề tương ứng – $\mathbf{A}_0$ (self + đồng hop), $\mathbf{A}_1$ (hướng tâm), $\mathbf{A}_2$ (ly tâm) – mỗi ma trận dùng một bộ trọng số tích chập riêng, cho phép mô hình học phân biệt tín hiệu truyền theo hai chiều đối lập của cấu trúc xương. Chúng tôi sử dụng chiến lược này ($K = 3$) trong toàn bộ các thực nghiệm.

D. Tích Chập Thời Gian

Sau khi tích chập đồ thị tổng hợp thông tin không gian, một tích chập thời gian (TCN) với kernel $\Gamma \times 1$ được áp dụng trên chiều thời gian của mỗi node. Điều này mở rộng khái niệm lân cận lên cả chiều thời gian:

$$B(v_{ti}) = \left\{ v_{qj} \mid d(v_{qj}, v_{ti}) \leq 1,\ |q - t| \leq \lfloor \Gamma/2 \rfloor \right\}. \tag{4}$$

Với $\Gamma = 9$ (kernel 9 frame) – giá trị mặc định từ bài báo gốc được giữ nguyên trong triển khai của chúng tôi – mỗi node có thể nhìn thấy ± 4 frame xung quanh, tương ứng cửa sổ thời gian $\approx$ 0,28 giây ở 32 fps. Với chuỗi FX được lấy mẫu về 48 frame, kernel này bao phủ khoảng 19% độ dài chuỗi mỗi bước – đủ rộng để nắm bắt các pha chuyển động cục bộ mà không bỏ qua phụ thuộc tầm xa.

E. Trọng Số Tầm Quan Trọng Cạnh Có Thể Học

Trong GCN chuẩn, tầm quan trọng mỗi cạnh được xác định hoàn toàn bởi cấu trúc đồ thị cố định (ma trận kề $\mathbf{A}$). ST-GCN bổ sung một ma trận mặt nạ $\mathbf{M}_k$ *có thể học* cho mỗi tập phân vùng k, nhân theo phần tử (Hadamard) với ma trận kề:

$$\mathbf{f}_{\text{out}} = \sum_k \mathbf{\Lambda}_k^{-\frac{1}{2}} (\mathbf{A}_k \odot \mathbf{M}_k) \mathbf{\Lambda}_k^{-\frac{1}{2}} \mathbf{f}_{\text{in}} \mathbf{W}_k, \tag{5}$$

trong đó $\mathbf{\Lambda}_k^{ii} = \sum_j (\mathbf{A}_k^{ij} + \mathbf{I}^{ij})$ là ma trận bậc chuẩn hóa và $\odot$ là tích Hadamard. $\mathbf{M}_k$ được khởi tạo bằng ma trận đơn vị (hành vi ban đầu giống GCN chuẩn) và được học end-to-end cùng phần còn lại của mạng. Cơ chế này cho phép mô hình tự điều chỉnh tầm quan trọng của từng cạnh theo từng kênh đặc trưng – ví dụ, trong một số hành động thể dục tự do, khớp cổ tay và mắt cá chân có thể mang nhiều thông tin phân biệt hơn khớp hông, và mặt nạ $\mathbf{M}_k$ sẽ phản ánh điều này sau khi huấn luyện.

F. Kiến Trúc Mạng

Hình 4 minh họa pipeline tổng thể. Kiến trúc cụ thể trong triển khai của chúng tôi xếp chồng **9 block ST-GCN**, theo cấu hình ban đầu của [1]. Mỗi block gồm: lớp tích chập đồ thị (GCN) với phân vùng cấu hình không gian ($K = 3$), tiếp theo là lớp tích chập thời gian (TCN) kernel 9×1, batch normalization, và kết nối tắt (residual). Bảng 3 tóm tắt cấu hình.

Sau 9 block, *global average pooling* (GAP) rút gọn chiều thời gian và không gian về 1, cho ra vector đặc trưng 256 chiều. Một lớp fully-connected chiếu vector này thành 35 điểm số lớp (cho tập FX). Batch normalization đầu vào được áp dụng trên chiều $C \times V = 2 \times 18 = 36$ để chuẩn hóa tọa độ keypoint thô trước block đầu tiên.

Bảng 3
CẤU HÌNH CÁC BLOCK ST-GCN. BLOCK 1 KHÔNG CÓ KẾT NỐI TẮT VÌ SỐ KÊNH VÀO (2) KHÁC KÊNH RA (64); CÁC BLOCK CÒN LẠI DÙNG KẾT NỐI TẮT VỚI CHIẾU 1×1 KHI STRIDE$= 2$.

Block	Kênh vào	Kênh ra	Stride	Residual
1	2	64	1	Không
2	64	64	1	Có
3	64	64	1	Có
4	64	128	2	Có
5	128	128	1	Có
6	128	128	1	Có
7	128	256	2	Có
8	256	256	1	Có
9	256	256	1	Có

G. Kiến Trúc Hai Luồng

Luồng joint nhận tensor $\mathbf{X}^{(j)} \in \mathbb{R}^{N\times 2\times 48\times 18}$ là tọa độ (x, y) tuyệt đối của các khớp. Luồng bone nhận tensor $\mathbf{X}^{(b)} \in \mathbb{R}^{N\times 2\times 48\times 18}$, trong đó mỗi node v được gán véc-tơ xương: $\mathbf{x}_v^{(b)} = \mathbf{x}_v^{(j)} - \mathbf{x}_u^{(j)}$, với u là khớp gốc của cạnh (u, v) trong đồ thị. Hai mô hình ST-GCN được huấn luyện độc lập với cùng kiến trúc. Tại suy luận, điểm logit được kết hợp tuyến tính:

$$\mathbf{s}_{\text{final}} = \alpha\, \mathbf{s}^{(j)} + (1 - \alpha)\, \mathbf{s}^{(b)}, \tag{6}$$

với $\alpha = 0{,}5$ trong cấu hình cơ sở (tương đương phép cộng bằng nhau như đề xuất gốc [2]). Giá trị α tối ưu có thể được chỉnh theo tập xác nhận.

Hai luồng bổ trợ nhau theo ý tưởng sau: luồng joint mã hóa vị trí tuyệt đối và dịch chuyển toàn cục, trong khi luồng bone mã hóa tư thế tương đối (góc khớp, độ dài chi) bất biến với vị trí. Trong nhận dạng hành động thể dục tự do – nơi các động tác chỉ khác nhau ở góc và thứ tự chuyển động của tay chân – thông tin tư thế tương đối từ luồng bone đặc biệt có giá trị.

H. Kỹ Thuật Tối Ưu và Chống Overfitting

Tập FX có hai đặc điểm đặt ra thách thức tối ưu hóa: mất cân bằng lớp (tỉ lệ $8\times$) và không gian đặc trưng mịn (các lớp FX rất tương đồng về tư thế). Chúng tôi áp dụng các kỹ thuật sau:

1) Focal Loss: CrossEntropy chuẩn bị phạt tất cả mẫu như nhau, dẫn đến thiên lệch học về các lớp đa số. Focal Loss [16] giảm đóng góp của các mẫu dễ phân loại bằng cách nhân thêm hệ số $(1 - p_t)^\gamma$:

$$\mathcal{L}_{\text{FL}}(p_t) = -\alpha_t (1 - p_t)^\gamma \log p_t, \tag{7}$$

với $\gamma = 2{,}0$ và $\alpha_t = 1/\sqrt{f_t}$ (nghịch đảo căn bậc hai tần suất lớp f_t, chuẩn hóa về tổng = 1). Điều này buộc mô hình tập trung học vào các mẫu khó và các lớp thiểu số.

2) Chuẩn Hóa Bounding-Box: Tọa độ keypoint gốc nằm trong không gian pixel (1920×1080) và phụ thuộc vào vị trí, tầm vóc vận động viên trong khung hình. Chuẩn hóa bounding-box (`bbox_norm`) co giãn tọa độ (x, y) về $[0, 1]$ trong hộp giới hạn khung xương mỗi frame, loại bỏ thông tin vị trí tuyệt đối và tỉ lệ người. Thay thế cho cách tiếp cận này là chuẩn hóa trung tâm (`center_norm`) – trừ tọa độ node trung tâm – bảo toàn thông tin tỉ lệ tương đối nhưng vẫn phụ thuộc tầm vóc.

3) Lịch Trình Học với Khởi Động: Vì dữ liệu mất cân bằng lớp khá nặng nên chúng tôi thử dùng Focal Loss cho cấu hình hai luồng. Learning rate đặt lớn ở giai đoạn đầu sẽ làm hàm mất mát dao động mạnh. Chúng tôi dùng *linear warmup* 8 epoch (tăng tuyến tính từ 0 đến $lr_{\max} = 10^{-3}$), tiếp theo là *cosine annealing* cho phần còn lại. Chiến lược này cho phép mạng ổn định biểu diễn ban đầu và hội tụ ổn định ở giai đoạn sau.

4) Tăng Cường Dữ Liệu và Lấy Mẫu Cân Bằng: Chúng tôi áp dụng chính sách tăng cường tùy chỉnh cho tập FX: lật ngang (xác suất $p = 0{,}5$), biến đổi tỉ lệ ngẫu nhiên trong $[0{,}95, 1{,}05]$, xoay ngẫu nhiên $\pm 10°$, dropout khớp ngẫu nhiên, và lấy mẫu thời gian ngẫu nhiên. Để giải quyết mất cân bằng lớp, chúng tôi sử dụng *weighted sampler* kết hợp hệ số oversample $3\times$ cho các lớp thiểu số, đảm bảo mỗi mini-batch có phân phối lớp đồng đều hơn. Gradient clipping (norm $= 1{,}0$) và weight decay (5×10^{-4}) được dùng để ổn định huấn luyện và kiểm soát overfitting.

V. THỰC NGHIỆM

A. Thiết Lập Thực Nghiệm

Tất cả thực nghiệm được tiến hành trên nền tảng Kaggle với GPU NVIDIA T4 (16 GB VRAM). Bộ tối ưu Adam với $lr = 10^{-3}$ được dùng xuyên suốt. Tập dữ liệu FX gồm 5.824 chuỗi huấn luyện và 2.411 chuỗi xác nhận (35 lớp); các chuỗi khung xương được căn chỉnh thời gian về $T = 48$ frame. Chúng tôi tiến hành ba thực nghiệm theo trình tự để xác định cấu hình tối ưu:

Giao thức đánh giá: Các chỉ số trong bảng kết quả được đo trực tiếp trên tập xác nhận trong quá trình huấn luyện sau khi lọc các mẫu hỏng (keypoint bằng 0 trên $> 5\%$ khung hình và khớp). Đây là giao thức thống nhất cho cả ba thực nghiệm, cho phép so sánh trực tiếp giữa các cấu hình.

1) **Baseline**: Mô hình đơn luồng với cấu hình tối thiểu.
2) **Kết hợp đầy đủ**: Hai luồng cùng nhiều kỹ thuật tăng cường đồng thời.
3) **Tìm kiếm độ sâu**: Hai luồng với cấu hình chỉnh lại và khảo sát số block.

B. Mô Hình Cơ Sở

Mô hình cơ sở là ST-GCN đơn luồng (joint stream) với chuẩn hóa trung tâm (`center_norm`), hàm mất mát CrossEntropy, và *weighted sampler* để giải quyết mất cân bằng lớp. Cấu hình huấn luyện: 80 epoch, batch size 128, không có warmup, weight decay 10^{-4}.

Hình 7 cho thấy mô hình hội tụ tốt và liên tục qua 80 epoch. Val accuracy đạt đỉnh **88,95%** tại epoch 73; train accuracy leo lên 99,66%, cho thấy có overfitting nhẹ ở giai đoạn cuối. Macro F1 tốt nhất đạt **87,41%** tại epoch 67. Đây là điểm chuẩn để so sánh cho các thực nghiệm tiếp theo.

C. Thử Nghiệm Kết Hợp Đầy Đủ

Từ mô hình cơ sở, chúng tôi đồng thời áp dụng nhiều thay đổi: kiến trúc hai luồng (joint + bone), chuẩn hóa bounding-box (`bbox_norm`), Focal Loss ($\gamma = 2{,}0$, $\alpha_t = 1/\sqrt{f_t}$), linear warmup 8 epoch, oversample $3\times$ lớp thiểu số, và tăng cường

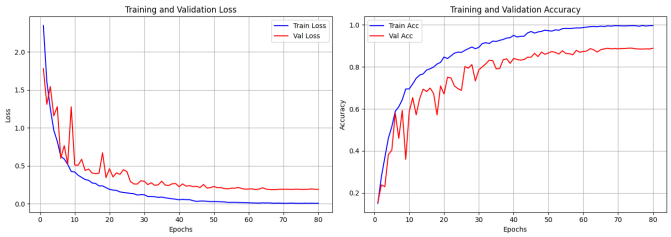

Hình 7. Đường cong huấn luyện mô hình Baseline (đơn luồng, center_norm, 80 epoch). Train accuracy đạt 99,66%; val accuracy ổn định quanh 88–89% từ epoch 60.

dữ liệu mạnh. Cấu hình: 70 epoch, batch size 32, weight decay 5×10^{-4}.

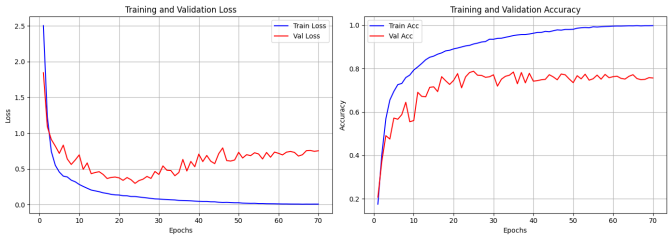

Hình 8. Đường cong huấn luyện thực nghiệm kết hợp đầy đủ (hai luồng, bbox_norm, Focal Loss, 70 epoch). Val accuracy đạt đỉnh 78,82% tại epoch 25 rồi suy giảm liên tục trong khi train accuracy tăng lên 99,84% — dấu hiệu quá khớp nặng.

Hình 8 cho thấy rõ sự phân kỳ: val accuracy đạt đỉnh **78,82%** tại epoch 25 rồi suy giảm về 75,70% sau 70 epoch — thấp hơn đáng kể so với baseline (88,95%) — trong khi train accuracy tiếp tục tăng lên 99,84%. Macro F1 tốt nhất chỉ đạt **71,30%** tại epoch 21, cũng thấp hơn nhiều so với baseline (87,41%). Tham số dung hòa hai luồng hội tụ về $\alpha = 0{,}686$ (joint) và $1 - \alpha = 0{,}314$ (bone).

Phân tích chỉ ra ba nguyên nhân chính: (1) `bbox_norm` co giãn tọa độ về $[0, 1]$ trong hộp giới hạn mỗi frame, loại bỏ thông tin tỉ lệ tuyệt đối giữa các chi — thông tin quan trọng để phân biệt các động tác FX chỉ khác nhau ở mức độ dãn duỗi và góc chân tay; (2) oversample $3\times$ tạo quá nhiều bản sao mẫu thiểu số, đẩy nhanh quá khớp; (3) không có cơ chế dừng sớm khiến mô hình tiếp tục học sau khi đã vượt qua điểm tối ưu (epoch 25).

D. Tìm Kiếm Độ Sâu Mạng

Rút kinh nghiệm từ thực nghiệm trước, chúng tôi giữ lại các thành phần có cơ sở lý luận rõ ràng (hai luồng, Focal Loss, weighted sampler), đồng thời quay lại `center_norm` và bổ sung dừng sớm (patience $= 10$ epoch). Chúng tôi khảo sát ba mức độ sâu (số block ST-GCN trên mỗi luồng): 4, 6, và 8 block. Cấu hình chung: batch size 64, tối đa 100 epoch, weight decay 5×10^{-4}, grad clip $= 1{,}0$.

Bảng 4 tổng kết kết quả. Trong nhóm hai luồng, depth = 6 vượt trội ở cả hai chỉ số: Best Val Acc = 89,68% tại epoch 93 và Macro F1 = 87,19%. Depth = 8 đứng thứ hai (87,76% / 84,59%), trong khi depth = 4 đạt kết quả thấp nhất trong nhóm (85,01% / 82,77%). Gap train–val của depth = 6 (9,81%) nhỏ hơn depth = 4 (12,70%), cho thấy độ sâu trung bình cân bằng tốt hơn giữa sức chứa mô hình và khả năng khái quát hóa.

Bảng 4
KẾT QUẢ TÌM KIẾM ĐỘ SÂU — TWO-STREAM ST-GCN TRÊN TẬP FX (35 LỚP, 2.411 MẪU XÁC NHẬN)

Depth	Best Val Acc	@Epoch	Gap*	Macro F1
4	85,01%	47	+12,70%	82,77%
6	**89,68%**	93	+9,81%	**87,19%**
8	87,76%	66	+9,43%	84,59%

*Gap = Final Train Acc − Final Val Acc.

Hình 9 cho thấy cả ba độ sâu đều huấn luyện ổn định nhờ dừng sớm và `center_norm`, trái ngược hoàn toàn với sự phân kỳ của thực nghiệm kết hợp đầy đủ (Hình 8).

E. Tổng Kết và Phân Tích

Bảng 5 tổng hợp kết quả ba thực nghiệm.

Bảng 5
SO SÁNH TỔNG THỂ CÁC CẤU HÌNH (BEST VAL ACC VÀ MACRO F1 TỐT NHẤT TRONG QUÁ TRÌNH HUẤN LUYỆN, GIAO THỨC THỐNG NHẤT)

Cấu hình	Best Val Acc	Best Macro F1
Baseline (1 luồng, center, CE)	**88,95%**	**87,41%**
Kết hợp đầy đủ (2 luồng, bbox, Focal)	78,82%	71,30%
Depth=4 (2 luồng, center, Focal)	85,01%	82,77%
Depth=6 (2 luồng, center, Focal)	**89,68%**	**87,19%**
Depth=8 (2 luồng, center, Focal)	87,76%	84,59%

Ba quan sát chính từ chuỗi thực nghiệm:

(1) Chuẩn hóa bbox gây hại cho bài toán này. So sánh hai cấu hình hai luồng: kết hợp đầy đủ với `bbox_norm` chỉ đạt Best Val Acc = 78,82% — thấp hơn baseline 10,13%. Trong khi đó, depth search với `center_norm` đạt kết quả tương đương baseline. `bbox_norm` co giãn tọa độ về $[0, 1]$ trong hộp giới hạn mỗi frame, loại bỏ thông tin tỉ lệ tuyệt đối giữa các chi — thông tin cần thiết để phân biệt các động tác FX chi tiết.

(2) Hai luồng + Focal Loss không tự động vượt trội baseline khi cấu hình sai. Dưới cùng giao thức đánh giá, Depth=6 (89,68% / 87,19%) chỉ ngang bằng Baseline (88,95% / 87,41%). Kết quả tốt của depth search so với kết hợp đầy đủ chủ yếu đến từ việc tránh `bbox_norm` và oversample $3\times$, kết hợp với dừng sớm — chứ không phải từ kiến trúc hai luồng đơn thuần.

(3) Độ sâu 6 block là điểm cân bằng tối ưu trong khung hai luồng. Depth = 4 thiếu sức chứa để mô hình hóa chuỗi thời gian dài; depth = 8 bắt đầu quá khớp sớm hơn. Depth = 6 đạt điểm cân bằng tốt nhất giữa khả năng biểu diễn và khái quát hóa.

VI. KẾT LUẬN

Chúng tôi đã trình bày quá trình xây dựng và thực nghiệm có hệ thống ST-GCN cho bài toán nhận dạng hành động thể dục tự do chi tiết trên tập con FX của Gym99 (35 lớp, 8.235

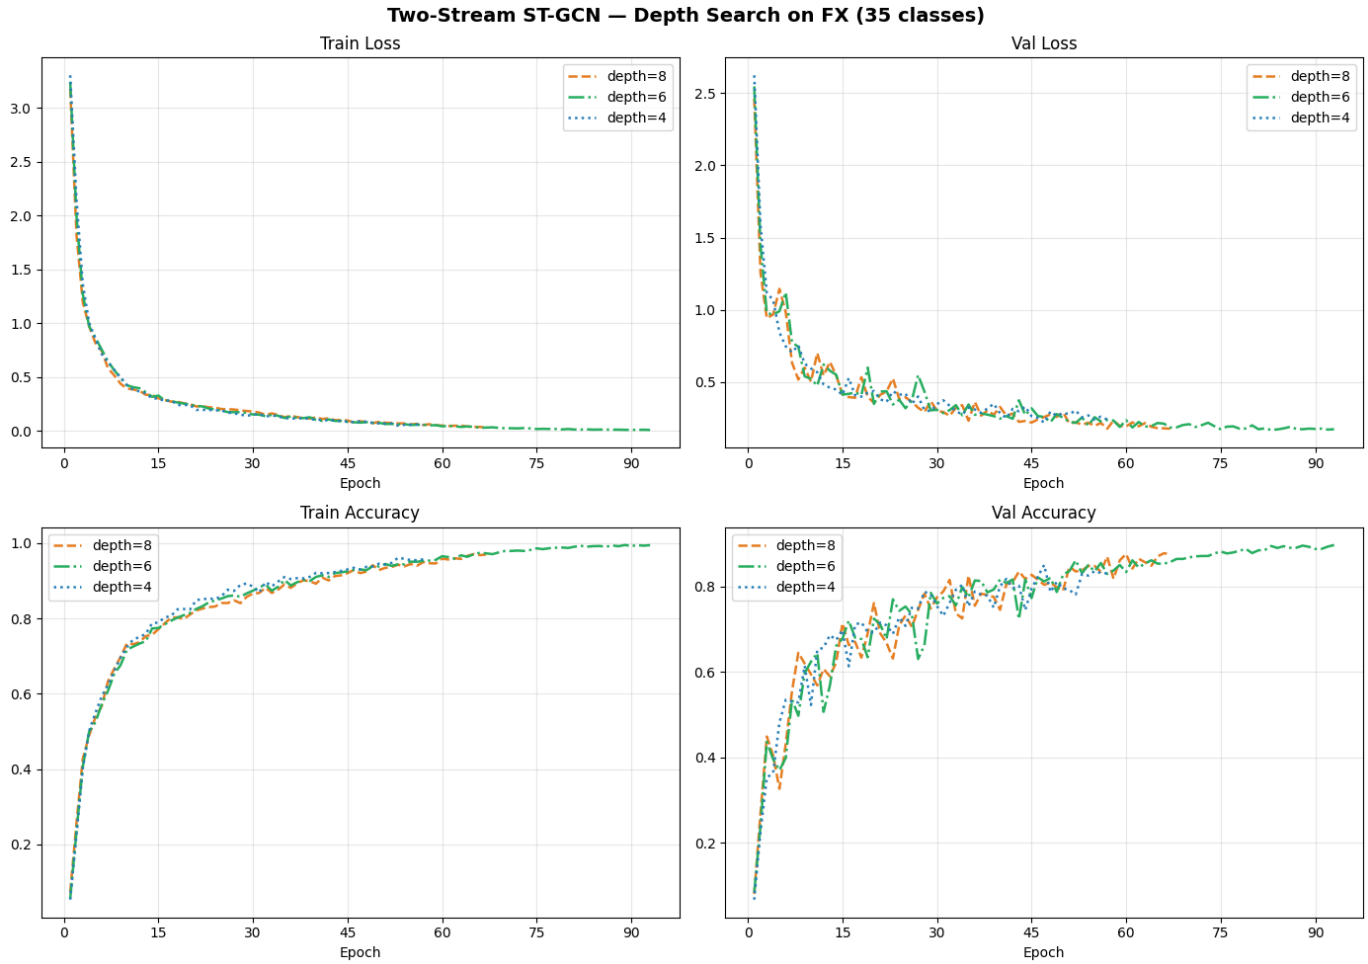

Hình 9. So sánh đường cong Train/Val Loss và Train/Val Accuracy giữa ba độ sâu (depth=4: xanh dương, depth=6: xanh lá, depth=8: cam). Depth=6 đạt val accuracy cao nhất và hội tụ ổn định đến epoch 93; depth=4 hội tụ sớm hơn nhưng kém hơn ở độ chính xác tối đa.

chuỗi). Dưới giao thức đánh giá thống nhất, mô hình đơn luồng cơ sở đạt Best Val Acc = 88,95%, Macro F1 = 87,41%. Kiến trúc hai luồng với 6 block, chuẩn hóa trung tâm, Focal Loss và dừng sớm đạt kết quả tương đương: **Best Val Acc = 89,68%, Macro F1 = 87,19%**.

Phát hiện quan trọng nhất là chuẩn hóa bounding-box gây hại nghiêm trọng cho nhận dạng chi tiết ($-10{,}13\%$ so với baseline) do loại bỏ thông tin tỉ lệ cơ thể. Oversample quá mức ($3\times$) kết hợp với thiếu dừng sớm dẫn đến quá khớp sớm và không thể phục hồi. Dừng sớm là yếu tố quan trọng để kiểm soát overfitting trên tập dữ liệu cỡ vừa với nhiều lớp tương đồng về đặc trưng.

Các hướng nghiên cứu tiếp theo bao gồm: (i) tích hợp luồng motion (sai phân tọa độ theo thời gian) như trong các công trình hậu ST-GCN; (ii) áp dụng ma trận kề có thể học thích nghi [2] để nắm bắt phụ thuộc ngữ nghĩa vượt ra ngoài cấu trúc giải phẫu; (iii) mở rộng lên toàn bộ 99 lớp Gym99 với kiến trúc chuyên gia theo bộ môn thể dục dụng cụ.

TÀI LIỆU

[1] S. Yan, Y. Xiong, and D. Lin, "Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition," in *Proc. AAAI Conf. Artif. Intell.*, 2018.

[2] L. Shi, Y. Zhang, J. Cheng, and H. Lu, "Two-Stream Adaptive Graph Convolutional Networks for Skeleton-Based Action Recognition," in *Proc. IEEE CVPR*, 2019.

[3] Z. Liu, H. Zhang, Z. Chen, Z. Wang, and W. Ouyang, "Disentangling and Unifying Graph Convolutions for Skeleton-Based Action Recognition," in *Proc. IEEE CVPR*, 2020.

[4] Y. Chen, Z. Zhang, C. Yuan, B. Li, Y. Deng, and W. Hu, "Channel-wise Topology Refinement Graph Convolution for Skeleton-Based Action Recognition," in *Proc. IEEE ICCV*, 2021.

[5] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," in *Proc. ICLR*, 2017.

[6] J. Bruna, W. Zaremba, A. Szlam, and Y. LeCun, "Spectral Networks and Locally Connected Networks on Graphs," in *Proc. ICLR*, 2014.

[7] M. Niepert, M. Ahmed, and K. Kutzkov, "Learning Convolutional Neural Networks for Graphs," in *Proc. ICML*, 2016.

[8] A. Shahroudy, J. Liu, T.-T. Ng, and G. Wang, "NTU RGB+D: A Large Scale Dataset for 3D Human Activity Analysis," in *Proc. IEEE CVPR*, 2016.

[9] J. Liu, A. Shahroudy, D. Xu, and G. Wang, "Spatio-Temporal LSTM with Trust Gates for 3D Human Action Recognition," in *Proc. ECCV*, 2016.

[10] T. S. Kim and A. Reiter, "Interpretable 3D Human Action Analysis with Temporal Convolutional Networks," in *Proc. IEEE CVPR Workshops*, 2017.

[11] M. E. Hussein, M. Torki, M. A. Gowayyed, and M. El-Saban, "Human Action Recognition Using a Temporal Hierarchy of Covariance Descriptors on 3D Joint Locations," in *Proc. IJCAI*, 2013.

[12] J. Wang, Z. Liu, Y. Wu, and J. Yuan, "Mining Actionlet Ensemble for Action Recognition with Depth Cameras," in *Proc. IEEE CVPR*, 2012.
[13] R. Vemulapalli, F. Arrate, and R. Chellappa, "Human Action Recognition by Representing 3D Skeletons as Points in a Lie Group," in *Proc. IEEE CVPR*, 2014.
[14] D. Shao, Y. Zhao, B. Dai, and D. Lin, "FineGym: A Hierarchical Video Dataset for Fine-grained Action Understanding," in *Proc. IEEE CVPR*, 2020.
[15] K. Zhou, Y. Liu, Y. Qiao, and T. Xiang, "Learning Discriminative Features for Fine-grained Skeleton-Based Action Recognition," *Pattern Recognition*, 2023.
[16] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal Loss for Dense Object Detection," in *Proc. IEEE ICCV*, 2017.