Nhận Dạng Động Tác Thể Dục Dụng Cụ Với Mạng Tích Chập Đồ Thị Không-Thời Gian Bằng Khung Xương

Đỗ Nhật Minh
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Lê Anh Duy
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

***Tóm tắt nội dung*—Bài báo này trình bày ứng dụng Mạng Tích Chập Đồ Thị Không-Thời Gian (ST-GCN) cho bài toán nhận dạng hành động thể dục dụng cụ hạt nhỏ trên tập dữ liệu Gym99 – một tập con gồm 99 lớp hành động thuộc bộ FineGym với 36.665 chuỗi khung xương. Khung xương được biểu diễn dưới dạng đồ thị không-thời gian với 18 node (17 khớp COCO và một node trung tâm ảo), được xử lý bởi kiến trúc hai luồng (joint stream và bone stream) kết hợp với chiến lược phân vùng cấu hình không gian. Chúng tôi phân tích ảnh hưởng của chuẩn hóa bounding-box và lịch trình khởi động learning rate lên quá trình huấn luyện trên tập dữ liệu quy mô lớn không cân bằng này.**

***Index Terms*—nhận dạng hành động hạt nhỏ, khung xương, ST-GCN, FineGym, Gym99, tích chập đồ thị, hai luồng**

I. Giới Thiệu

Nhận dạng hành động người (Human Action Recognition – HAR) là một trong những bài toán trung tâm của thị giác máy tính, với ứng dụng rộng rãi trong phân tích thể thao, giám sát an ninh, và hỗ trợ y tế phục hồi chức năng [1]. Gần đây, nghiên cứu trong lĩnh vực này đang dịch chuyển từ nhận dạng ở cấp độ *thô* (coarse-grained) – phân biệt "chạy" với "đứng" – sang nhận dạng *hạt nhỏ* (fine-grained), đòi hỏi phân biệt các biến thể tinh tế trong cùng một loại hành động. Thể dục dụng cụ là miền ứng dụng đặc biệt thách thức: các động tác như "lăn ra trước" và "lăn ra sau" có cấu trúc khung xương gần như đối xứng, trong khi sự khác biệt nằm ở thứ tự và pha thời gian của các khớp.

Các phương pháp HAR truyền thống dựa trên đặc trưng RGB thô nhạy cảm với điều kiện ngoại cảnh như ánh sáng, trang phục và góc máy quay. Phương pháp dựa trên khung xương [1] khắc phục hạn chế này bằng cách biểu diễn cơ thể người dưới dạng đồ thị có cấu trúc, bất biến với nhiều biến đổi quang học. Đặc biệt, ST-GCN (Spatial Temporal Graph Convolutional Networks) của Yan *và cộng sự* [1] là mô hình đầu tiên áp dụng tích chập đồ thị lên chuỗi khung xương động, học đồng thời cấu trúc không gian của cơ thể và sự tiến hóa thời gian của chuyển động.

Tập dữ liệu FineGym [14] được giới thiệu nhằm thúc đẩy nghiên cứu nhận dạng hành động hạt nhỏ, đặc biệt trong lĩnh vực thể dục nghệ thuật và thể dục dụng cụ. Gym99 là tập con của FineGym gồm 99 lớp hành động cụ thể, với khoảng 36.665 chuỗi khung xương được trích xuất từ video thi đấu thực tế. Sự không cân bằng lớp đáng kể (tỉ lệ lớp lớn nhất/nhỏ nhất lên tới 26 lần), độ dài chuỗi đa dạng, và tính tương đồng trực quan cao giữa các lớp đặt ra những thách thức phi tầm thường cho các mô hình phân loại.

Bài báo này có các đóng góp sau:

- Ứng dụng và đánh giá ST-GCN hai luồng (joint + bone) trên Gym99, một tập dữ liệu hạt nhỏ quy mô lớn chưa được khám phá rộng rãi với kiến trúc dựa trên đồ thị.
- Thiết kế biểu diễn khung xương 18 node thống nhất (COCO-17 + node trung tâm ảo) tương thích với cả hai luồng joint và bone, cho phép tái sử dụng pipeline trên nhiều tập dữ liệu khác nhau.
- Phân tích thực nghiệm tác động của chuẩn hóa bounding-box và lịch trình học có khởi động (warm-up learning rate) lên hiệu năng trên bộ dữ liệu không cân bằng.
- Áp dụng hàm mất mát Focal Loss với hệ số α theo căn bậc hai nghịch đảo tần suất lớp, giảm thiểu độ lệch học do mất cân bằng lớp.

Phần còn lại của bài báo được tổ chức như sau: Phần II tổng quan các nghiên cứu liên quan; Phần III mô tả tập dữ liệu Gym99; Phần IV trình bày chi tiết kiến trúc ST-GCN và các lựa chọn thiết kế; Phần V báo cáo kết quả thực nghiệm; Phần VI kết luận.

II. Các Nghiên Cứu Liên Quan

A. Nhận Dạng Hành Động Dựa Trên Khung Xương

Hướng nghiên cứu dựa trên khung xương khai thác tọa độ 2D/3D của các khớp cơ thể người như một biểu diễn gọn nhẹ, bất biến với nhiều biến đổi ngoại cảnh. Các phương pháp sơm sử dụng các đặc trưng thủ công như hiệp phương sai quỹ đạo khớp [11], vị trí tương đối giữa các khớp [12], hay góc xoay và tịnh tiến giữa các phần cơ thể [13]. Sự ra đời của học sâu đã thúc đẩy việc sử dụng mạng hồi tiếp (RNN/LSTM) để mô hình hóa chuỗi thời gian khớp [8], [9], và sau đó là mạng tích chập thời gian (TCN) [10].

Bước đột phá quan trọng đến từ ST-GCN [1]: thay vì làm phẳng khung xương thành vector một chiều, mô hình xây dựng đồ thị không-thời gian và áp dụng tích chập đồ thị học không gian cùng tích chập thời gian học động học. Tiếp theo, AGCN [2] đề xuất ma trận kề có thể học được để nắm bắt phụ

thuộc ngữ nghĩa không nhất thiết gắn với kết nối giải phẫu; MS-G3D [3] thống nhất tích chập đa tỉ lệ không gian và thời gian vào một toán tử duy nhất; CTR-GCN [4] tập trung học biến đổi kênh theo ngữ cảnh cho từng mẫu đầu vào.

B. Mạng Tích Chập Đồ Thị

Nền tảng lý thuyết của ST-GCN là mạng tích chập đồ thị (GCN). Hai hướng chính hình thành GCN là hướng *phổ* (spectral), xử lý tín hiệu trên đồ thị qua biến đổi Fourier đồ thị [5], [6], và hướng *không gian* (spatial), định nghĩa tích chập trực tiếp trên các hàng xóm trong không gian đồ thị [7]. ST-GCN theo hướng không gian và phân vùng tập hàng xóm của mỗi node thành K tập con ứng với K ma trận kề – mỗi ma trận học một bộ trọng số tích chập riêng. Chiến lược phân vùng cấu hình không gian (Spatial Configuration Partitioning) phân chia hàng xóm theo khoảng cách đến tâm trọng lực của khung xương, phản ánh tính chất tâm-ngoại tâm của chuyển động cơ thể.

C. Mô Hình Hai Luồng Cho Khung Xương

Shi *và cộng sự* [2] chỉ ra rằng kết hợp thông tin khớp (joint) và thông tin xương (bone – véc-tơ sai phân giữa hai đầu mỗi cạnh) trong hai luồng song song cải thiện đáng kể hiệu năng phân loại. Luồng joint mã hóa vị trí tuyệt đối của các khớp; luồng bone mã hóa độ dài và hướng của từng đoạn xương, bất biến hơn với dịch chuyển toàn cục. Tại thời điểm suy luận, điểm số phân loại từ hai luồng được cộng trực tiếp (score fusion). Kiến trúc này trở thành thực hành chuẩn trong nhiều công trình kế tiếp.

D. Nhận Dạng Hành Động Hạt Nhỏ Trong Thể Thao

FineGym [14] là tập dữ liệu hành động hạt nhỏ đầu tiên tập trung vào thể dục nghệ thuật, với ba cấp độ phân loại phân cấp: sự kiện (event), tố chất (element), và hành động chi tiết. Gym288 và Gym99 là hai tập con phổ biến được dùng làm benchmark. Điểm đặc trưng của dữ liệu này là: (1) sự tương đồng trực quan rất cao giữa nhiều lớp; (2) mất cân bằng lớp nghiêm trọng; (3) biến đổi lớn trong độ dài clip; (4) video từ camera cố định trong thi đấu thực tế, tạo ra phân phối rất khác so với dataset dân dụng thông thường. Một số nghiên cứu gần đây sử dụng đặc trưng RGB kết hợp [14] hoặc attention cấu trúc đồ thị [15] để giải quyết bài toán này; tuy nhiên, hướng tiếp cận chỉ dùng khung xương trên Gym99 vẫn còn ít được khám phá.

III. Tập Dữ Liệu Gym99

A. Xây Dựng Từ FineGym288

Gym99 không tồn tại dưới dạng tập độc lập; chúng tôi xây dựng nó bằng cách lọc bộ chú thích FineGym288 [14] theo danh sách lớp chính thức của Gym99. Quy trình gồm ba bước: (1) tải tệp danh mục của cả Gym288 và Gym99 từ trang chủ FineGym để xây dựng bảng ánh xạ nhãn cục bộ sang nhãn toàn cục (*clabel* $\rightarrow$ *glabel*); (2) lọc các mẫu trong Gym288 có nhãn toàn cục xuất hiện trong tập 99 lớp của Gym99; (3) gán lại nhãn về khoảng $[0, 98]$.

Bảng 1
Thống Kê Tập Dữ Liệu Gym99

Thuộc tính	Giá trị
Tổng số mẫu	36.665
Tập huấn luyện	27.624
Tập kiểm tra	9.041
Số lớp hành động	99
Số khớp mỗi frame	17 (COCO) + 1 (trung tâm) = 18
Độ dài chuỗi (sau lấy mẫu lại)	48 frame
Số mẫu lớp nhỏ nhất	79
Số mẫu lớp lớn nhất	2.060
Tỉ lệ mất cân bằng max/min	$\approx$26$\times$
Gini coefficient	0,438

Gym99 bao phủ bốn dụng cụ thể dục: Vault (VT, nhãn $[0, 5]$, 6 lớp), Floor Exercise (FX, nhãn $[6, 40]$, 35 lớp), Balance Beam (BB, nhãn $[41, 73]$, 33 lớp), và Uneven Bars (UB, nhãn $[74, 98]$, 25 lớp). Các thực nghiệm trong bài báo này tập trung vào tập con **FX**.

Bảng 1 tóm tắt đặc điểm của tập dữ liệu sau khi xây dựng. Tổng cộng 96,2% mẫu Gym288 được ánh xạ trực tiếp; phần còn lại sử dụng nhãn lân cận (± 1) để giải quyết lệch chỉ số giữa hai phiên bản danh mục.

B. Biểu Diễn Khung Xương

Bộ chú thích FineGym288 lưu trữ keypoint theo định dạng COCO-17: tensor $(1, T, 17, 2)$ với tọa độ pixel trong không gian ảnh gốc (1920×1080). Chúng tôi giữ nguyên tất cả 17 khớp bao gồm cả các điểm mặt (mắt, tai) vì chúng đóng góp vào phân vùng hướng tâm/ly tâm của đồ thị. Một **node trung tâm ảo** (chỉ số 17) được thêm vào như trung bình của bốn khớp gốc:

$$\mathbf{p}_{17} = \frac{1}{4}\big(\mathbf{p}_{\text{l_sho}} + \mathbf{p}_{\text{r_sho}} + \mathbf{p}_{\text{l_hip}} + \mathbf{p}_{\text{r_hip}}\big).$$

Tensor đầu vào cho ST-GCN có dạng $(N, C{=}2, T{=}48, V{=}18, M{=}1)$ trong đó C là số kênh tọa độ (x, y), T là số frame (lấy mẫu lại đều về 48), V là số node, và M là số người.

Nhánh bone được tạo bằng cách tính sai phân véc-tơ theo từng cạnh của đồ thị khung xương: với mỗi cạnh (u, v), đặc trưng bone là $\mathbf{p}_v - \mathbf{p}_u$ (hướng từ gốc sang ngọn). Điều này tạo ra tensor bone cùng hình dạng với tensor joint.

C. Phân Tích Tập Con FX

Thống kê tổng quan. Tập FX gồm 35 lớp hành động (nhãn toàn cục $[6, 40]$), với 5.824 mẫu huấn luyện và 2.411 mẫu kiểm tra (tổng 8.235). So với toàn bộ Gym99, mức độ mất cân bằng lớp thấp hơn đáng kể: tỉ lệ max/min là $8\times$ (thay vì $26\times$) và Gini = 0,306 (thay vì 0,438), với effective number of classes đạt 30,1/35. Hình III-C minh họa phân phối lớp và đường cong Lorenz của tập FX.

Phân tích không gian và chuyển động. Tọa độ keypoint gốc nằm trong không gian ảnh pixel (1920×1080), với tâm khung xương ở vị trí trung bình ($\bar{x} \approx 1088$, $\bar{y} \approx 488$) px. Hình III-C cho thấy các khớp chi trên (cổ tay, khuỷu tay) và chi dưới (mắt cá chân, đầu gối) có vận tốc trung bình cao hơn

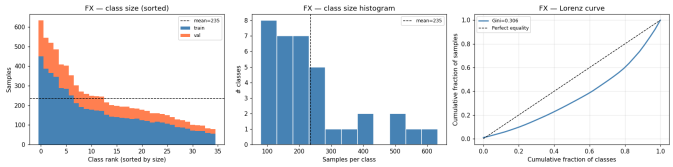

Hình 1. Phân phối lớp tập con FX: (trái) số mẫu mỗi lớp sắp xếp giảm dần (train xanh / val cam); (giữa) histogram số mẫu/lớp; (phải) đường Lorenz – Gini = 0,306.

đáng kể so với các khớp trục thân (hông, vai), phản ánh đặc trưng động học của bài thể dục tự do.

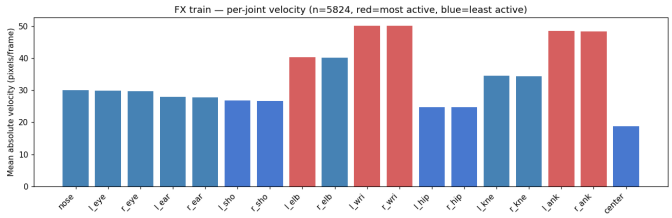

Hình 2. Vận tốc tuyệt đối trung bình theo từng khớp COCO-18 trên tập huấn luyện FX. Đỏ = Q3 trở lên (hoạt động nhất); xanh dương = Q1 trở xuống (ít hoạt động nhất).

Khả năng phân tách lớp. Hình III-C trình bày PCA hai chiều trên đặc trưng trung bình thời gian (36 chiều) của 20 lớp phổ biến nhất. Sự chồng chéo lớp cao trong không gian 2D xác nhận tính chất fine-grained của tập FX: các bài tập tự do có cấu trúc khung xương rất tương đồng, sự khác biệt chủ yếu nằm ở thứ tự và pha thời gian của động tác.

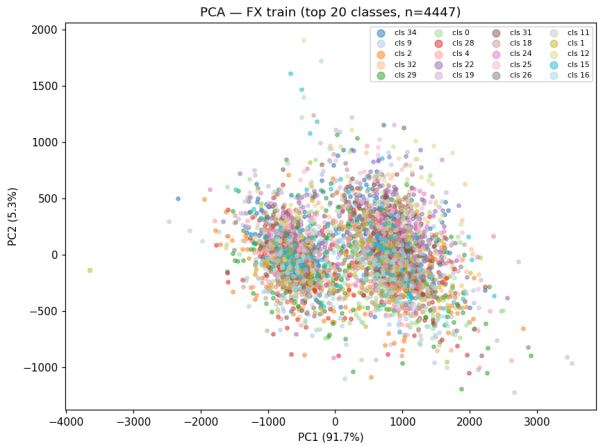

Hình 3. PCA hai chiều trên 20 lớp phổ biến nhất của tập FX (train). Sự chồng chéo cao giữa các lớp xác nhận tính chất fine-grained của bài toán phân loại.

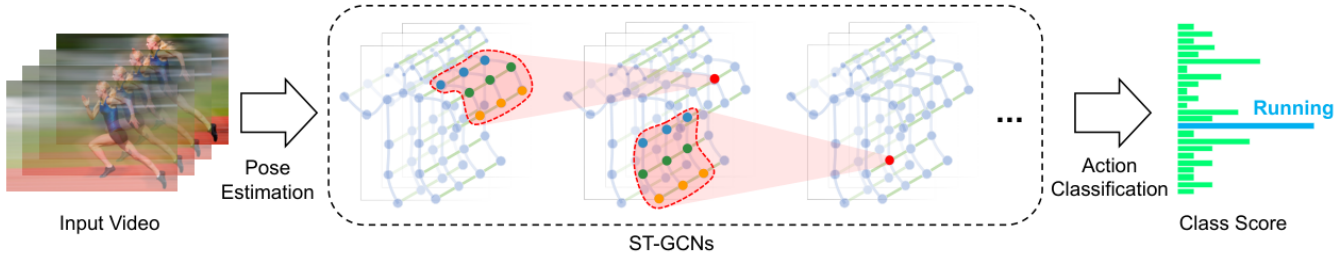

Hình 4. Pipeline tổng quát của ST-GCN (hình từ bài báo gốc [1]): ước lượng tư thế từ video đầu vào, xây dựng đồ thị không-thời gian, áp dụng nhiều lớp ST-GCN và phân loại bằng Softmax.

IV. Kiến Trúc ST-GCN

A. Đồ Thị Không-Thời Gian

ST-GCN [1] biểu diễn một chuỗi khung xương N khớp trong T frame dưới dạng đồ thị không định hướng $\mathcal{G} = (\mathcal{V}, \mathcal{E})$. Tập node $\mathcal{V} = \{v_{ti} \mid t = 1, \ldots, T;\ i = 1, \ldots, N\}$ gồm $T \times N$ node, mỗi node ứng với khớp i tại frame t. Tập cạnh $\mathcal{E}$ chia thành hai loại (Hình IV-A):

- **Cạnh không gian** $\mathcal{E}_S$: nối các khớp có kết nối giải phẫu trong cùng một frame, phản ánh cấu trúc xương người. Chúng ta có $\{v_{ti}v_{tj} \mid (i,j) \in H\}$, trong đó H là tập cạnh xương.
- **Cạnh thời gian** $\mathcal{E}_F$: nối cùng một khớp giữa hai frame liên tiếp, mã hóa quỹ đạo chuyển động. $\{v_{ti}v_{(t+1)i}\}$ cho mọi t và i.

Đồ thị khung xương 18 node của chúng tôi bao gồm 19 cạnh không gian giải phẫu (theo cấu trúc COCO-17) cộng thêm 4 cạnh nối node trung tâm ảo với hai vai và hai hông.

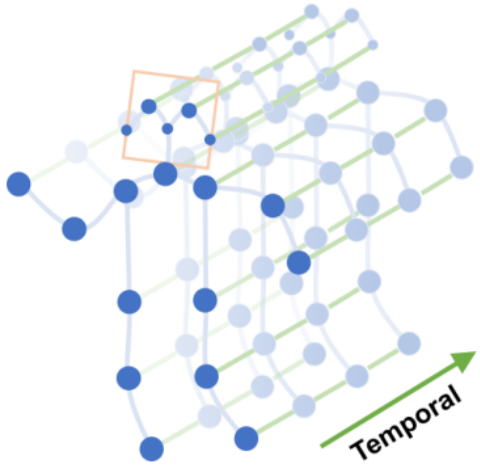

Hình 5. Đồ thị không-thời gian của chuỗi khung xương trong ST-GCN (hình từ bài báo gốc [1]). **Chấm xanh đậm**: node khớp; **cạnh xanh ngang**: kết nối giải phẫu trong cùng frame ($\mathcal{E}_S$); **cạnh xanh lá chéo**: liên kết thời gian giữa các frame liên tiếp ($\mathcal{E}_F$); **hình chữ nhật cam**: vùng tiếp nhận của một bộ lọc (D=1). Chiều thời gian tăng theo hướng mũi tên.

B. Tích Chập Đồ Thị Không Gian

Trong không gian ảnh 2D chuẩn, tích chập được định nghĩa qua một hàm lấy mẫu và một hàm trọng số:

$$f_{\text{out}}(\mathbf{x}) = \sum_{h=1}^{K} \sum_{w=1}^{K} f_{\text{in}}\big(\mathbf{p}(\mathbf{x}, h, w)\big) \cdot \mathbf{w}(h, w), \tag{1}$$

trong đó $\mathbf{p}$ liệt kê các điểm lân cận và $\mathbf{w}$ là hàm trọng số. ST-GCN mở rộng công thức này lên đồ thị bằng cách định nghĩa lại hàm lấy mẫu trên tập lân cận $B(v_{ti})$ của node v_{ti}:

$$f_{\text{out}}(v_{ti}) = \sum_{v_{tj} \in B(v_{ti})} \frac{1}{Z_{ti}(v_{tj})} f_{\text{in}}(v_{tj}) \cdot \mathbf{w}\big(l_{ti}(v_{tj})\big), \tag{2}$$

trong đó $Z_{ti}(v_{tj}) = |\{v_{tk} \mid l_{ti}(v_{tk}) = l_{ti}(v_{tj})\}|$ là số phần tử trong cùng tập phân vùng (chuẩn hóa theo bậc), và $l_{ti} : B(v_{ti}) \to \{0, \ldots, K-1\}$ là ánh xạ nhãn phân vùng.

C. Chiến Lược Phân Vùng

Ánh xạ nhãn l_{ti} quyết định cách chia tập hàng xóm thành K tập con (Hình 2). ST-GCN đề xuất ba chiến lược:

1) Uni-labeling ($K = 1$): Toàn bộ tập hàng xóm được gán cùng nhãn: $l_{ti}(v_{tj}) = 0,\ \forall i, j$. Đây là chiến lược đơn giản nhất, tương đương với lan truyền đồng nhất của GCN chuẩn [5], nhưng làm mất thông tin về cấu trúc cục bộ.

2) Distance Partitioning ($K = 2$): Phân vùng theo khoảng cách đến node gốc: node gốc ở tập $d = 0$, hàng xóm ở tập $d = 1$: $l_{ti}(v_{tj}) = d(v_{tj}, v_{ti})$. Chiến lược này cho phép mô hình học khác biệt giữa node trung tâm và các khớp lân cận.

3) Spatial Configuration Partitioning ($K = 3$): Node hàng xóm được phân vùng dựa trên khoảng cách của nó đến tâm trọng lực khung xương so với khoảng cách của node gốc:

$$l_{ti}(v_{tj}) = \begin{cases} 0 & \text{nếu } r_j = r_i \quad \text{(self-loop / đồng khoảng cách)} \\ 1 & \text{nếu } r_j < r_i \quad \text{(hướng tâm)} \\ 2 & \text{nếu } r_j > r_i \quad \text{(ly tâm)} \end{cases} \tag{3}$$

trong đó r_i là khoảng cách trung bình từ tâm trọng lực đến khớp i tính trên toàn bộ tập huấn luyện. Chiến lược này dựa trên quan sát rằng chuyển động cơ thể có thể được phân tích thành hai thành phần: *hướng tâm* (chuyển động hướng vào thân người) và *ly tâm* (chuyển động ra xa thân người), tương ứng với các lớp cơ khác nhau trong sinh lý học vận động. Đây là chiến lược được sử dụng trong triển khai của chúng tôi.

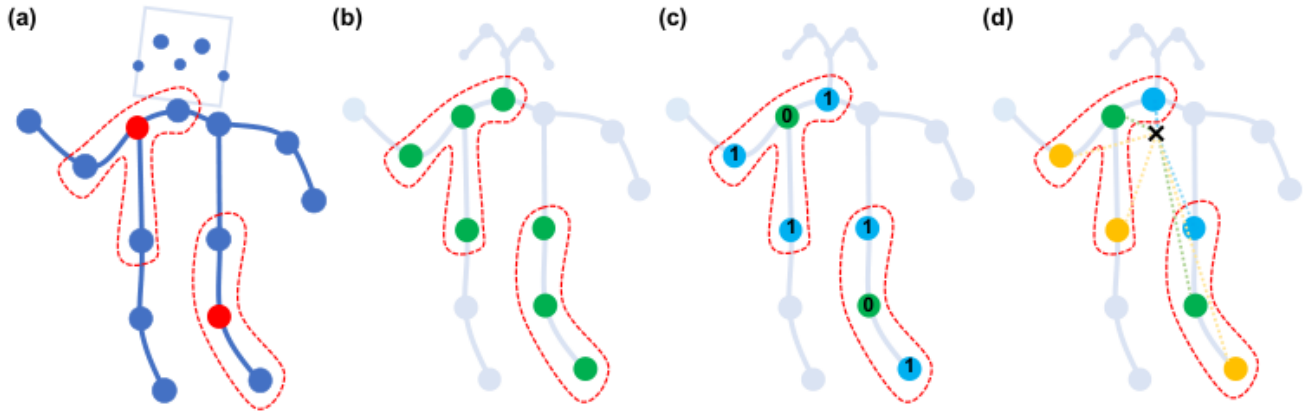

Hình 6. Ba chiến lược phân vùng của ST-GCN (hình từ bài báo gốc [1]): (a) ví dụ frame khung xương; (b) Uni-labeling: mọi hàng xóm cùng nhãn (xanh lá); (c) Distance partitioning: node gốc (xanh lá) và hàng xóm (xanh lam); (d) Spatial configuration: hướng tâm (xanh lam) và ly tâm (vàng).

D. Tích Chập Thời Gian

Sau khi tích chập đồ thị tổng hợp thông tin không gian, một tích chập thời gian (TCN) với kernel $\Gamma \times 1$ được áp dụng trên chiều thời gian của mỗi node. Điều này mở rộng khái niệm lân cận lên cả chiều thời gian:

$$B(v_{ti}) = \{v_{qj} \mid d(v_{qj}, v_{ti}) \leq 1,\ |q - t| \leq \lfloor \Gamma/2 \rfloor\}. \tag{4}$$

Với $\Gamma = 9$ (kernel 9 frame), mỗi node có thể nhìn thấy ± 4 frame xung quanh, cho phép nắm bắt động học cục bộ trong cửa sổ thời gian ≈ 0.28 giây (tương ứng 32 fps).

E. Trọng Số Tầm Quan Trọng Cạnh Có Thể Học

Một cải tiến quan trọng của ST-GCN so với GCN chuẩn là việc thêm một ma trận mặt nạ có thể học $\mathbf{M}$ vào mỗi lớp tích chập đồ thị:

$$\mathbf{f}_{\text{out}} = \mathbf{\Lambda}^{-\frac{1}{2}}(\mathbf{A} + \mathbf{I})\mathbf{\Lambda}^{-\frac{1}{2}}\mathbf{f}_{\text{in}}\mathbf{W}, \tag{5}$$

và đối với phân vùng nhiều tập con:

$$\mathbf{f}_{\text{out}} = \sum_k \mathbf{\Lambda}_k^{-\frac{1}{2}}(\mathbf{A}_k \odot \mathbf{M}_k)\mathbf{\Lambda}_k^{-\frac{1}{2}}\mathbf{f}_{\text{in}}\mathbf{W}_k, \tag{6}$$

trong đó $\odot$ là tích Hadamard và $\mathbf{M}_k$ được khởi tạo là ma trận đơn vị. Ma trận mặt nạ cho phép mô hình tự điều chỉnh tầm quan trọng của từng cạnh đồ thị theo từng lớp và từng kênh đặc trưng, thay vì cố định theo cấu trúc giải phẫu. Điều này đặc biệt hữu ích cho Gym99: trong một số hành động, các khớp chi dưới có thể ít liên quan hơn chi trên.

F. Kiến Trúc Mạng

Hình 1 minh họa pipeline tổng thể. Kiến trúc cụ thể trong triển khai của chúng tôi xếp chồng **9 block ST-GCN**, theo cấu hình ban đầu của [1]. Mỗi block gồm: lớp tích chập đồ thị (GCN) với phân vùng cấu hình không gian ($K = 3$), tiếp theo là lớp tích chập thời gian (TCN) kernel 9×1, batch normalization, và kết nối tắt (residual). Bảng 2 tóm tắt cấu hình.

Bảng 2
CẤU HÌNH CÁC BLOCK ST-GCN

Block	Kênh vào	Kênh ra	Stride	Residual
1	2	64	1	Không
2	64	64	1	Có
3	64	64	1	Có
4	64	128	2	Có
5	128	128	1	Có
6	128	128	1	Có
7	128	256	2	Có
8	256	256	1	Có
9	256	256	1	Có

Sau 9 block, *global average pooling* (GAP) rút gọn chiều thời gian về 1, và một lớp tích chập 1×1 chiếu vector đặc trưng 256 chiều thành 99 điểm số lớp. Batch normalization đầu vào được áp dụng trên chiều $C \times V = 2 \times 18 = 36$ để chuẩn hóa tọa độ đầu vào trước khi truyền vào block đầu tiên.

G. Kiến Trúc Hai Luồng

Luồng joint nhận tensor $\mathbf{X}^{(j)} \in \mathbb{R}^{N \times 2 \times 48 \times 18}$ là tọa độ (x, y) của các khớp. Luồng bone nhận tensor $\mathbf{X}^{(b)} \in \mathbb{R}^{N \times 2 \times 48 \times 18}$ là véc-tơ xương: với mỗi cạnh (u, v) trong đồ thị, $\mathbf{x}_v^{(b)} = \mathbf{x}_v^{(j)} - \mathbf{x}_u^{(j)}$. Hai mô hình ST-GCN được huấn luyện độc lập với cùng kiến trúc và siêu tham số. Tại thời điểm suy luận, điểm logit được tổng hợp bằng phép cộng có trọng số bằng nhau:

$$\mathbf{s}_{\text{final}} = \mathbf{s}^{(j)} + \mathbf{s}^{(b)}. \tag{7}$$

Luồng joint nhạy cảm hơn với vị trí tuyệt đối và sự dịch chuyển toàn cục của khung xương. Luồng bone bổ sung thông tin về tư thế tương đối (góc khớp và độ dài chi), bất biến hơn với vị trí tuyệt đối. Sự kết hợp hai nguồn thông tin bổ trợ nhau giúp tăng độ chính xác phân loại, đặc biệt trong nhận dạng hành động hạt nhỏ nơi sự khác biệt chủ yếu nằm ở tư thế tương đối chứ không phải vị trí trong không gian.

V. Thực Nghiệm

A. Thiết Lập Huấn Luyện

Mô hình được huấn luyện trên Google Colab và Kaggle với GPU NVIDIA T4. Optimizer: Adam ($lr = 10^{-3}$, weight decay $= 10^{-4}$); learning rate scheduler: Linear Warmup 10 epoch tiếp theo Cosine Annealing; batch size: 64; số epoch: 90; hàm mất mát: Focal Loss ($\gamma = 2,0$, α theo căn bậc hai nghịch đảo tần suất lớp). Chuẩn hóa bounding-box theo từng mẫu được áp dụng trước khi đưa vào mô hình.

VI. Kết Luận

Chúng tôi đã trình bày ứng dụng ST-GCN hai luồng cho bài toán nhận dạng hành động thể dục dụng cụ hạt nhỏ trên Gym99 – một tập dữ liệu quy mô lớn, nhiều lớp, và mất cân bằng nghiêm trọng. Sự lựa chọn biểu diễn khung xương 18 node (COCO-17 + trung tâm ảo), chiến lược phân vùng cấu hình không gian, và hàm mất mát Focal Loss tạo thành một hệ thống tích hợp chặt chẽ cho bài toán này. Các hướng nghiên cứu tiếp theo bao gồm: (i) tích hợp luồng motion (sai phân tọa độ theo thời gian) như trong các công trình hậu ST-GCN; (ii) áp dụng ma trận kề có thể học thích nghi (AGCN) để nắm bắt phụ thuộc ngữ nghĩa vượt ra ngoài cấu trúc giải phẫu; (iii) khai thác cấu trúc phân cấp của FineGym (event $\rightarrow$ element $\rightarrow$ action) thông qua học có giám sát đa nhiệm vụ.

Tài liệu

[1] S. Yan, Y. Xiong, and D. Lin, "Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition," in *Proc. AAAI Conf. Artif. Intell.*, 2018.

[2] L. Shi, Y. Zhang, J. Cheng, and H. Lu, "Two-Stream Adaptive Graph Convolutional Networks for Skeleton-Based Action Recognition," in *Proc. IEEE CVPR*, 2019.

[3] Z. Liu, H. Zhang, Z. Chen, Z. Wang, and W. Ouyang, "Disentangling and Unifying Graph Convolutions for Skeleton-Based Action Recognition," in *Proc. IEEE CVPR*, 2020.

[4] Y. Chen, Z. Zhang, C. Yuan, B. Li, Y. Deng, and W. Hu, "Channel-wise Topology Refinement Graph Convolution for Skeleton-Based Action Recognition," in *Proc. IEEE ICCV*, 2021.

[5] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," in *Proc. ICLR*, 2017.

[6] J. Bruna, W. Zaremba, A. Szlam, and Y. LeCun, "Spectral Networks and Locally Connected Networks on Graphs," in *Proc. ICLR*, 2014.

[7] M. Niepert, M. Ahmed, and K. Kutzkov, "Learning Convolutional Neural Networks for Graphs," in *Proc. ICML*, 2016.

[8] A. Shahroudy, J. Liu, T.-T. Ng, and G. Wang, "NTU RGB+D: A Large Scale Dataset for 3D Human Activity Analysis," in *Proc. IEEE CVPR*, 2016.

[9] J. Liu, A. Shahroudy, D. Xu, and G. Wang, "Spatio-Temporal LSTM with Trust Gates for 3D Human Action Recognition," in *Proc. ECCV*, 2016.

[10] T. S. Kim and A. Reiter, "Interpretable 3D Human Action Analysis with Temporal Convolutional Networks," in *Proc. IEEE CVPR Workshops*, 2017.

[11] M. E. Hussein, M. Torki, M. A. Gowayyed, and M. El-Saban, "Human Action Recognition Using a Temporal Hierarchy of Covariance Descriptors on 3D Joint Locations," in *Proc. IJCAI*, 2013.

[12] J. Wang, Z. Liu, Y. Wu, and J. Yuan, "Mining Actionlet Ensemble for Action Recognition with Depth Cameras," in *Proc. IEEE CVPR*, 2012.

[13] R. Vemulapalli, F. Arrate, and R. Chellappa, "Human Action Recognition by Representing 3D Skeletons as Points in a Lie Group," in *Proc. IEEE CVPR*, 2014.

[14] D. Shao, Y. Zhao, B. Dai, and D. Lin, "FineGym: A Hierarchical Video Dataset for Fine-grained Action Understanding," in *Proc. IEEE CVPR*, 2020.

[15] K. Zhou, Y. Liu, Y. Qiao, and T. Xiang, "Learning Discriminative Features for Fine-grained Skeleton-Based Action Recognition," *Pattern Recognition*, 2023.